

# Data Engineering

Wintersemester 25/26

# Vorstellung

- Jannik Heyl (31)
- Master Informatik
- 5 Jahre Dozent an der TH Bingen, 1 Jahr in Worms
- CTO & Business Unit Lead Data & AI

# Stellt euch vor!

Name, Hintergrund & Erwartungshaltung

# Fragen an euch.

- Wer hat schon mal mit Data Warehouses gearbeitet?
- Kennt jemand NoSQL-Datenbanken?
- Hat jemand Erfahrungen mit Docker oder Kubernetes?
- Wer hat schon mal mit Python programmiert?
- Wer hat von ETL (Extract, Transform, Load) gehört?
- Kennt jemand den Begriff CDC (Change Data Capture)?

# Einführung in Data Engineering

# Definition

*„Data engineering is the development, implementation, and maintenance of systems and processes that take in raw data and produce high-quality, consistent information that supports downstream use cases, such as analysis and machine learning. Data engineering is the intersection of security, data management, DataOps, data architecture, orchestration, and software engineering. A data engineer manages the data engineering lifecycle, beginning with getting data from source systems and ending with serving data for use cases, such as analysis or machine learning.“*

Fundamentals of Data Engineering


Joe Reis

# Definition #2

*„Data engineering is all about the movement, manipulation, and management of data.“*

Lewis Gavin

# Wachstum




- **Hottest Field in Technology:** Data Engineering ist die Grundlage für Data Science und eine der gefragtesten Fähigkeiten im Technologiebereich.

# Nachfrage

DICE TECH JOB REPORT // Hottest Tech Occupations

## FASTEST GROWING TECH OCCUPATIONS

YEAR-OVER-YEAR GROWTH



- „Dice Tech Job Report stated Data engineering as the fastest-growing career in technology in 2019, with a 50% increase in open positions.“

# Einführung

- Zwei Typen des Data Engineering:
  - **SQL-basiertes Data Engineering** (klassische Datenbanken, Abfragen in SQL)
  - **Big Data-orientiertes Data Engineering** (Verarbeitung großer Datenmengen mit verschiedenen Tools)
- Der Data Engineer verwaltet den gesamten Lebenszyklus der Datenverarbeitung
  - Vom Dateneingang bis zur Bereitstellung für analytische und operative Systeme





Figure 1-1. The data engineering lifecycle

# Historie

# Anfänge 1970 – Relationale Datenbanken

- Konzept erfunden von E. F. Codd bei IBM
- Publiziert im Paper "*A Relational Model of Data for Large Shared Data Banks*"
- Ursprünglich definiert durch 12 Regeln  
(Codd's 12 Rules)
- Diese wurden als zu umfangreich angesehen, weshalb sie sich heute auf zwei Regeln beschränken




# Anfänge 1970 – Relationale Datenbanken

- Die zwei wesentlichen:
  - Daten müssen in Relationen präsentiert werden (Tabellen mit einem Set aus Zeilen und Reihen)
  - Relationale Operatoren um Daten in tabellarischer Form zu manipulieren
- Gegründet von IBM, populär gemacht durch Oracle
- Anfänge des strukturierten Datenmanagements

# Data Warehouse (80s)

- Data Warehouse (DWH) oder Enterprise Data Warehouse (EDW)
- System für **Berichterstellung und Datenanalyse**
- (Zentrale) Komponente der **Business Intelligence (BI)**



# Funktion

- **Zentrales Repository** für integrierte Daten aus verschiedenen Quellen
- Speicherung von **aktuellen und historischen Daten**
- Dient der Erstellung von Berichten und **Datenanalyse**
- **Unterstützt datengetriebene Entscheidungsfindung**

Warum macht man Analysen in  
einer gesonderten Datenbank?

# Aufstieg von Big Data (2000er/2010er)

- **Gründe für den Aufstieg:**
  - Wachstum der Datenmengen und der Bedarf an neuen Verarbeitungsstrategien mit Standard-Hardware
- **Die 3 V's von Big Data:**
  - **Velocity** (Geschwindigkeit der Daten), **Variety** (Vielfalt der Daten), **Volume** (Datenmenge)

# Meilensteine in der Big Data Entwicklung

- **Google File System (2003)** und **MapReduce (2004)**: Grundlage für skalierbare Datenverarbeitung
- **Yahoo und Hadoop (2006)**: Erste Implementierung eines Data-Lake-Ansatzes
- **Amazon Web Services (AWS)**: Einführung von EC2, S3, NoSQL-Datenbanken (DynamoDB) und flexilem Pay-as-you-go-Modell
- **Hadoop gewinnt schnell an Popularität**

Warum ist die Public Cloud  
elementar für die Entwicklung  
von Big Data?

# Data Lake in a nutshell

# Probleme relationaler DWHs

## DWHs halten keine Rohdaten

- Daten werden für spezifische Analysen ausgewählt, verdichtet und strukturiert
- Andersartige Analysen auf den selben Quelldaten lassen sich nicht mehr durchführen
- Design von Datenstrukturen und Aufbereitung der Daten ist sehr zeitaufwendig

## Big Data = Big Money

- Menge der Compute Ressourcen steigt linear mit der Menge der Daten (bei allen Datenbanken der Fall)
- Ungenutzte Daten (Cold Data) treiben die Kosten der Systeme in die Höhe
- Datenmengen werden systematisch reduziert um Kosten im Griff zu behalten

# Probleme relationaler DWHs


- Unstrukturierte und Semistrukturierte Daten sind für relationale DWHs ungeeignet
- Andere DBMs werden benötigt
- Analysen über Daten aus mehreren Quellen hinweg nur sehr schwer möglich
- Als zentrale Single Source of Truth für alle Daten im Unternehmen ungeeignet

# Herausforderungen

- **Von Batch- zu Stream-Processing:** Echtzeit-Datenverarbeitung als nächste Revolution
- **Zunehmende Komplexität:**
  - Immer mehr Tools, die für den Data Engineer erforderlich wurden: BI/Data Science Wissen, Softwareentwicklung, Infrastruktur, Automatisierung und verteilte Systeme

# Idee eines Data Lakes

- Komponenten einer Datenbank werden in **eigenständige**, voneinander unabhängige und **hochgradig skalierbare Systeme unterteilt**
- Keine Datenbank sondern **verteilter, skalierbarer Dateispeicher**
- Keine Abhängigkeit mehr zwischen Compute und Storage (bei Hadoop teilweise anders)
- Komponenten sind je nach Anwendungsfall austauschbar
- Keine Restriktion bezüglich Datenstruktur
- Zentrale Plattform für alle Daten einer Organisation



Zurück zur Historie ☺

# Big Data - Übermäßige Komplexität

- Unternehmen bauten komplexe Architekturen, die oft nicht den erwarteten Mehrwert brachten
- Tatsächliche Datenmengen sind oft sehr klein
- Hadoop und das Ökosystem sind sehr komplex zu betreiben
- Der klassische Data Lake Ansatz hat konzeptionelle Probleme

# Big Data in a nutshell

*„Big data is like teenage sex: everyone talks about it, nobody really knows how to do it, everyone thinks everyone else is doing it, so everyone claims they are doing it.”*

Dan Ariely

# Ende des Hypes

- Big Data ist in sehr vielen Unternehmen gescheitert
- Massive Investitionen, Datensümpfe, nicht nutzbare Daten, schwer zu betreibende Systeme
- Hadoop ist tot

# Die 2020er – Evolution der Systeme

- Modularisierung und Abstraktion von Frameworks
- Weniger low-level Arbeiten, mehr Management und Orchestrierung
- Das Data Lakehouse – Fusion aus Data Lake und Data Warehouse  
– funktionierende Data Lake Evolution
- Aufkommen des KI Hypes benötigt neue Datengrundlage

# Neue Herausforderungen und Aufgaben:

- Datenqualität, Datenschutz, Sicherheitsanforderungen
- **DataOps** und **Data Lifecycle Management** werden zentral
- Konzepte wie das „*Data Mesh*“ kommen auf

# Zunehmende Bedeutung von Data Engineering

- **Data Engineer** als zentrale Rolle, um Dateninfrastrukturen für Analytik, KI und maschinelles Lernen bereitzustellen

# Unterschied zwischen Data Engineering und Data Science

- **Ergänzend, aber unterschiedlich:**
  - Data Engineers arbeiten "upstream" (Datenvorbereitung, Infrastruktur)
  - Data Scientists arbeiten "downstream" (Modellierung, Analyse)
- **Data Engineering als Basis für erfolgreiche Data Science:**
  - 70-80% der Arbeit von Data Scientists und ML-Ingenieuren besteht aus der Datenaufbereitung
  - Solide Datenfundamente sind nötig, bevor man sich mit KI und maschinellem Lernen beschäftigt

# Aufgaben eines Data Engineers

- Datenaufbereitung, Bereinigung
- Datenmodellierung
- Schreiben und Orchestrieren von Datenpipelines
- Architektur verteilter Systeme, verteilte Speicherung und Verarbeitung

# Organisatorisches

# Prüfungsleistung: Projektarbeit

- **Projektaufgabe:**
  - Daten aus einer beliebigen Quelle laden (z.B. **Web Scraping**)
  - Daten **verarbeiten** und in einer geeigneten **Datenstruktur** speichern
  - Speichern der Daten in einem **System Ihrer Wahl**
- **Analyseteil:**
  - Führen Sie **Analysen** auf den verarbeiteten Daten durch
- **Auswahlmöglichkeiten:**
  - Klassischer Analytics Use Case
  - Such-Optimierung
  - Verarbeitung von Echtzeitdaten

# Studienleistung

- Keine...

# Abwesenheit

- 09.10.2025
- 30.10.2025
- 21.11.2025